

Lecture 4: *Analisis & Logika dari KSNP 2020**Lecturer: Hendra Bunyamin*

Notes ini membahas teori-teori dan soal-soal KSNP 2020. Referensi yang dapat digunakan oleh adik-adik adalah Aji and Gozali (2011).

## 4.1 Aritmetika Modular

(Aji and Gozali, 2011) Dalam subbab ini kita akan membahas **model** atau **hypothesis**, **cost function** atau **fungsi biaya**, dan **gradient descent** dari *regularized logistic regression* (Ng, 2021).

Perbedaan antara *logistic regression* dengan *regularized logistic regression* terletak pada bentuk *cost function* ( $J(\theta)$ ) dan bentuk *gradient* ( $\frac{\partial J}{\partial \theta}$ ) pada algoritma *gradient descent* yang digunakan.

**Cost function** atau fungsi biaya dari *regularized logistic regression* adalah sebagai berikut

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [-y^{(i)} \log h(x^{(i)}) - (1 - y^{(i)}) \log(1 - h(x^{(i)}))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2. \quad (4.1)$$

### Latihan

Sebagai contoh, diberikan  $\theta_0 = 1$ ,  $\theta_1 = 2$ , dan  $\theta_2 = 3$  sehingga model kita menjadi

$$h(x_1, x_2) = \frac{1}{1 + e^{-(1+2x_1+3x_2)}} \quad (4.2)$$

dengan dataset  $x^{(i)} = (x_1^{(i)}, x_2^{(i)})$  untuk  $i = 1, 2, 3, 4$  sebagai berikut

$$x^{(1)} = (1, 1), x^{(2)} = (1, 2), x^{(3)} = (2, 1), x^{(4)} = (2, 2) \quad (4.3)$$

dan

$$y^{(1)} = 1, y^{(2)} = 0, y^{(3)} = 1, y^{(4)} = 0. \quad (4.4)$$

Hitunglah *cost function* atau fungsi biaya dari model *regularized logistic regression* dengan  $\lambda = 1$  pada Persamaan (4.1).

Algoritma optimasi (*optimization algorithm*) yang digunakan masih tetap *gradient descent* seperti berikut

$$\begin{aligned}
 \theta_0 &= \theta_0 - \alpha \times \frac{\partial J}{\partial \theta_0} \\
 \theta_1 &= \theta_1 - \alpha \times \frac{\partial J}{\partial \theta_1} + \frac{\lambda}{m} \theta_1 \\
 \theta_2 &= \theta_2 - \alpha \times \frac{\partial J}{\partial \theta_2} + \frac{\lambda}{m} \theta_2 \\
 &\vdots \\
 \theta_n &= \theta_n - \alpha \times \frac{\partial J}{\partial \theta_n} + \frac{\lambda}{m} \theta_n
 \end{aligned} \tag{4.5}$$

dengan  $\frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1}, \dots, \frac{\partial J}{\partial \theta_n}$  adalah *gradient-gradient* untuk setiap  $\theta_i, i = 0, 1, \dots, n$ . Lebih spesifik,

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) \tag{4.6}$$

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \quad \text{dengan } j = 1, \dots, n \tag{4.7}$$

Oleh karena itu, dengan mensubstitusi Persamaan (4.6) dan Persamaan (4.7) ke Persamaan (4.5), kita peroleh

$$\theta_0 = \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) \text{ dan} \tag{4.8}$$

$$\theta_j = \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x_j^{(i)} + \frac{\lambda}{m} \theta_j \quad \text{untuk } j = 1, 2, \dots, n. \tag{4.9}$$

### Latihan

Dengan menggunakan dataset pada (4.3) dan (4.4) dan  $\alpha = 0.1$  dan  $\theta_0 = \theta_1 = \theta_2 = 0$ , hitunglah

- $\theta_0$  yang baru,
- $\theta_1$  yang baru, dan
- $\theta_2$  yang baru.

## 4.2 Softmax Regression

Untuk mengatasi masalah multi-class classification, *logistic regression* dapat digunakan. Selain menggunakan model

### Daftar Pustaka

- Aji, A. F. and Gozali, W. (2011). Pemrograman kompetitif dasar: Panduan memulai osn informatika, acm-icpc, dan sederajat versi 1.9. <https://toki.id/buku-pemrograman-kompetitif-dasar>.
- Ng, A. Y. (2021). Logistic regression. <https://www.coursera.org/learn/machine-learning/home/week/3>. Accessed: 2021-03-16.